AI VIET NAM – AI COURSE 2024

Ứng dụng RAG trong việc hỏi đáp tài liệu bài học AIO

Dinh-Thang Duong, Nguyen-Thuan Duong, Quang-Vinh Dinh

Ngày 23 tháng 6 năm 2024

I. Giới thiệu

Large Language Models (LLMs) (Tạm dịch: Các mô hình ngôn ngữ lớn) là loại mô hình cho phép người dùng nhập vào một văn bản với nội dung bất kì, thường sẽ là các yêu cầu hoặc câu hỏi. Từ đó, mô hình sẽ trả về câu trả lời dưới dạng văn bản thỏa mãn yêu cầu của người dùng. Các ứng dụng phổ biến nhất về LLMs có thể kể đến như ChatGPT, Gemini...

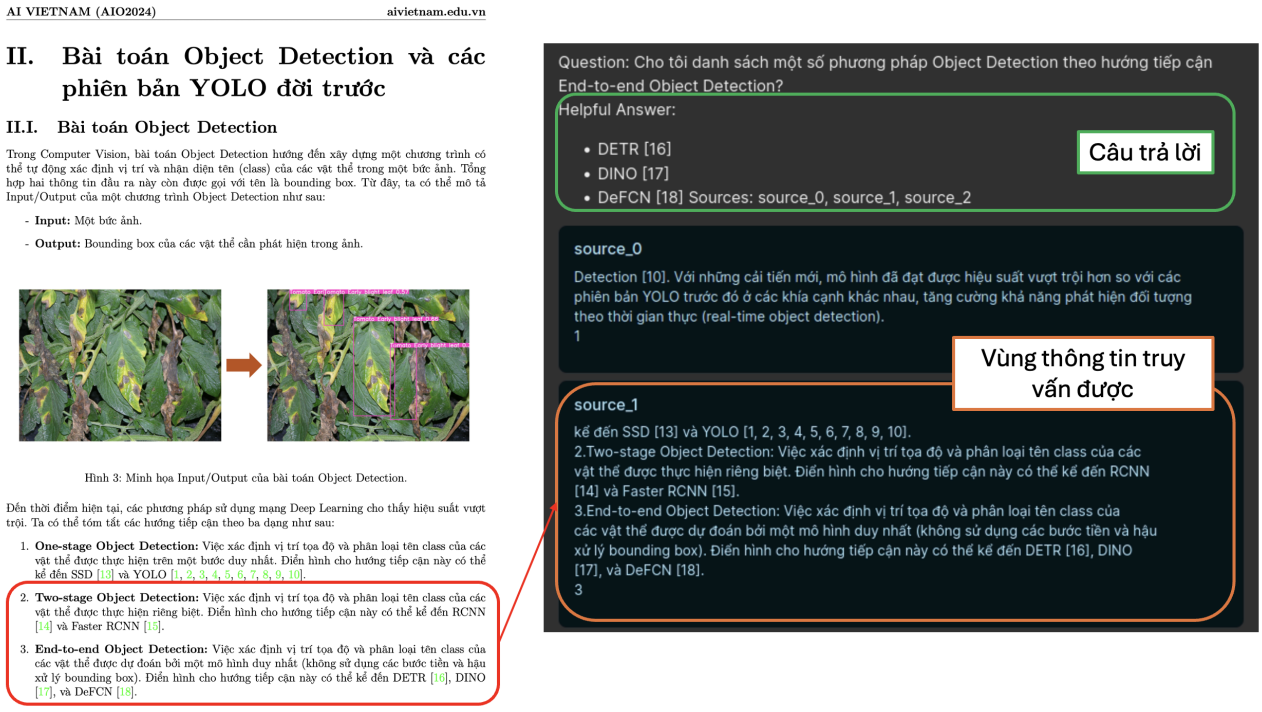

Hình 1: Sử dụng RAG trong việc hỏi đáp tài liệu về YOLOv10 trong AIO.

Trong LLMs, **Retrieval Augmented Generation (RAG)** là một kỹ thuật giúp LLMs cải thiện chất lượng kết quả tạo sinh bằng cách tích hợp nội dung truy vấn được từ một nguồn tài

liệu nào đó để trả lời cho một câu hỏi đầu vào. Trong project này, chúng ta sẽ tìm hiểu cách xây dựng một chương trình RAG cơ bản. Đồng thời, ứng dụng chương trình vào việc hỏi đáp tài liệu bài học trong khóa AIO. Theo đó, Input và Output của chương trình là:

- **Input:** File tài liệu cần hỏi đáp và một câu hỏi liên quan đến nội dung tài liệu.
- **Output:** Câu trả lời.

Tổng quan, luồng xử lý (pipeline) của chương trình RAG mà chúng ta sẽ xây dựng có dạng như sau:

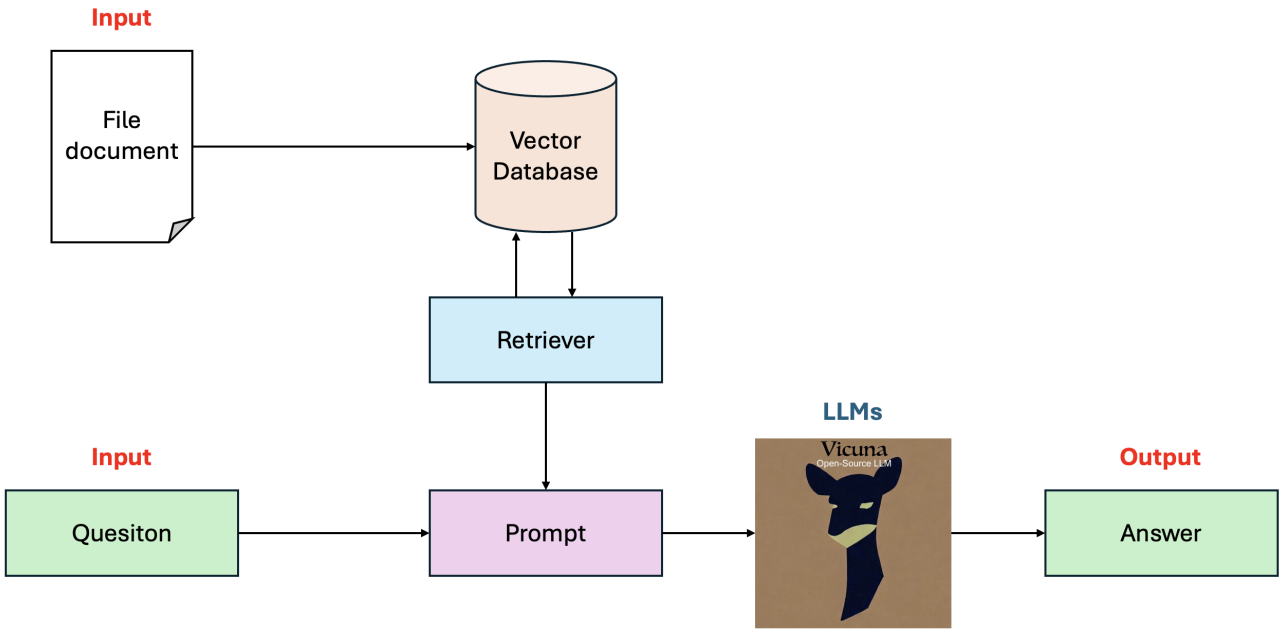

Hình 2: Pipeline của chương trình RAG trong project.

II. Cài đặt chương trình

Trong phần này, chúng ta sẽ tìm hiểu cách cài đặt chương trình RAG theo như mô tả ở phần trước, bao gồm phần chương trình RAG và phần giao diện chat (optional). Cả hai phần đều sẽ được thực hiện trên Google Colab đã được kích hoạt GPU. Lưu ý rằng, mục tiêu của project này hướng đến việc hiểu được một số khái niệm cơ bản về bài toán RAG trong AI. Vì vậy, các bạn có thể tạm thời không cần hiểu rõ các chức năng của các hàm, kỹ thuật sẽ được sử dụng trong bài.

II.I. Chương trình RAG

Trước tiên, chúng ta cần nắm được các bước xử lý cơ bản trong RAG bằng cách xây dựng một chương trình RAG đơn giản. Tại đây, ta sẽ sử dụng thư viện LangChain để thực hiện việc này. Các bước triển khai như sau:

Hình 3: Thư viện LangChain. Một thư viện được thiết kế chuyên biệt cho việc xây dựng các ứng dụng về LLMs. Ảnh: link.

1. **Cài đặt các gói thư viện cần thiết:** Thực hiện cài đặt một số gói thư viện thông qua lệnh pip install như sau:

```
!pip install -q transformers==4.41.2
!pip install -q bitsandbytes==0.43.1
!pip install -q accelerate==0.31.0
!pip install -q langchain==0.2.5
!pip install -q langchainhub==0.1.20
!pip install -q langchain-chroma==0.1.1
!pip install -q langchain-community==0.2.5
!pip install -q langchain_huggingface==0.0.3
!pip install -q python-dotenv==1.0.1
!pip install -q pypdf==4.2.0
!pip install -q numpy==1.24.4
```

2. **Xây dựng vector database:** Để thực hiện truy vấn, chúng ta cần phải có một cơ sở dữ liệu. Theo như nội dung project, với dữ liệu nguồn là một file pdf, chúng ta sẽ thực hiện

đưa các nội dung trong file này vào cơ sở dữ liệu. Về các bước thực hiện, các bạn có thể coi qua ảnh sau:

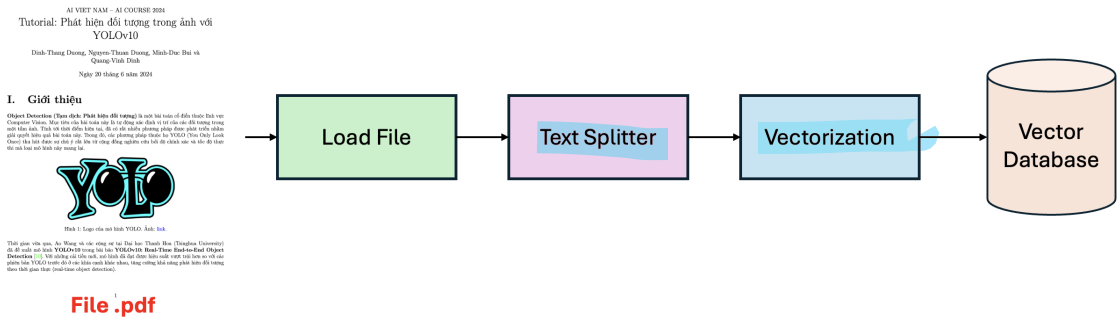

Hình 4: Pipeline các bước thực hiện xây dựng vector database.

(a) **Import các thư viện cần thiết:** Để xây dựng vector database, chúng ta cần một số thư viện sau:

```
import torch

from transformers import BitsAndBytesConfig
from transformers import AutoTokenizer, AutoModelForCausalLM,
    pipeline
from langchain_huggingface import HuggingFaceEmbeddings
from langchain_huggingface.llms import HuggingFacePipeline

from langchain.memory import ConversationBufferMemory
from langchain_community.chat_message_histories import
    ChatMessageHistory
from langchain_community.document_loaders import PyPDFLoader,
    TextLoader
from langchain.chains import ConversationalRetrievalChain

from langchain_chroma import Chroma
from langchain_text_splitters import RecursiveCharacterTextSplitter
from langchain_core.runnables import RunnablePassthrough
from langchain_core.output_parsers import StrOutputParser
from langchain import hub
```

(b) **Đọc file pdf:** Từ một file pdf cho trước (trong bài này ta sẽ sử dụng file mô tả là bài hướng dẫn YOLOv10, các bạn có thể tải file này tại đây), ta sử dụng class PyPDFLoader để đọc file pdf này lên như sau:

```
Loader = PyPDFLoader
FILE_PATH = "./AIO-2024-All-Materials.pdf"
loader = Loader(FILE_PATH)
documents = loader.load()
```

(c) **Khởi tạo bộ tách văn bản (text splitter):** Hầu hết các trường hợp, vùng thông tin mà chúng ta cần chỉ là một câu nào đó trong file văn bản lớn. Vì vậy, sẽ tốt hơn nếu chúng ta tách file văn bản ra thành các đoạn văn bản nhỏ, và mỗi văn bản nhỏ này ta sẽ coi như là một tài liệu trong cơ sở dữ liệu. Dựa vào ý tưởng trên, ta sẽ sử

dụng class Text Splitter để thực hiện tác vụ trên. Ở đây, ta khai báo instance text splitter như sau:

```
text_splitter = RecursiveCharacterTextSplitter(chunk_size=1000,
                                               chunk_overlap=100)
```

Với `text_splitter`, ta thực hiện tách file pdf:

```
docs = text_splitter.split_documents(documents)

print("Number of sub-documents: ", len(docs))
print(docs[0])
```

Ở hai dòng print trên, ta in số lượng tài liệu sau khi tách khỏi pdf và in nội dung tài liệu đầu tiên.

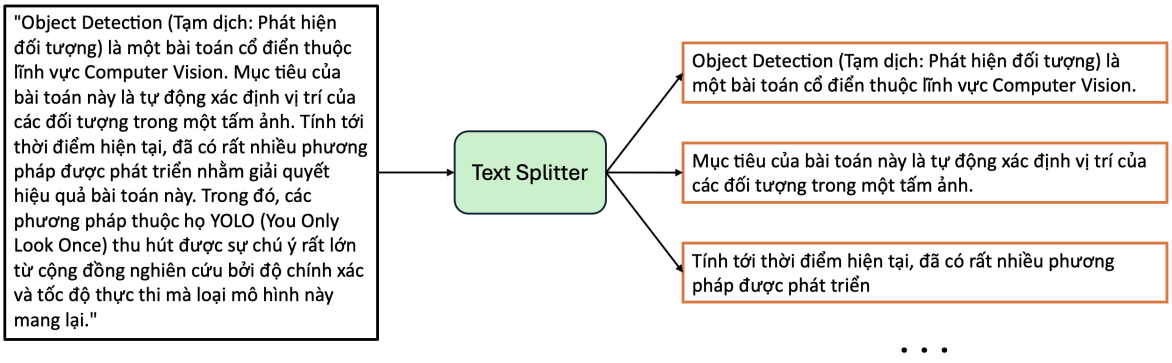

Hình 5: Minh họa việc tách văn bản lớn thành các văn bản nhỏ hơn.

(d) **Khởi tạo instance vectorization:** Các văn bản gốc được biểu diễn dưới dạng string. Nếu giữ dạng biểu diễn này, việc truy vấn sẽ gặp khó khăn và kết quả truy vấn không được chính xác. Để khắc phục việc này, chúng ta có thể thực hiện chuyển đổi các văn bản thành các vector. Trong file notebook, ta chạy đoạn code sau:

```
embedding = HuggingFaceEmbeddings()
```

`embedding` instance sẽ giúp chúng ta thực hiện việc chuyển đổi văn bản thành vector.

(e) **Khởi tạo vector database:** Với các thông tin về danh sách các documents (từ kết quả `text_splitter` và object dùng để vectorization `embedding`, ta sẽ đưa vào hàm dùng để khởi tạo vector database như sau:

```
vector_db = Chroma.from_documents(documents=docs,
                                  embedding=embedding)

retriever = vector_db.as_retriever()
```

Ta có thể thử thực hiện truy vấn với một đoạn văn bản bất kì tại đây:

```
result = retriever.invoke("What is YOLO?")

print("Number of relevant documents: ", len(result))
```

Kết quả của đoạn code này sẽ trả về cho ta danh sách các tài liệu có liên quan đến đoạn văn bản đầu vào.

3. **Khởi tạo mô hình ngôn ngữ lớn:** Trong project này, ta sẽ sử dụng mô hình Vicuna, một mô hình ngôn ngữ lớn nguồn mở có hiệu suất rất ổn, có thể phản hồi tốt với tiếng Việt. Các bạn có thể đọc thêm về mô hình Vicuna tại đây.

Hình 6: Mô hình Vicuna. Ảnh: link.

Một vấn đề của mô hình ngôn ngữ lớn đó là nó yêu cầu tài nguyên về phần cứng khá lớn. Vì vậy, để khởi tạo được mô hình Vicuna trên Colab, chúng ta sẽ cần thực hiện một số bước sau:

(a) **Khai báo một số cài đặt cần thiết cho mô hình:**

```
nf4_config = BitsAndBytesConfig(
    load_in_4bit=True,
    bnb_4bit_quant_type="nf4",
    bnb_4bit_use_double_quant=True,
    bnb_4bit_compute_dtype=torch.bfloat16
)
```

(b) **Khởi tạo mô hình và tokenizer:**

```
MODEL_NAME = "lmsys/vicuna-7b-v1.5"

model = AutoModelForCausalLM.from_pretrained(
    MODEL_NAME,
    quantization_config=nf4_config,
    low_cpu_mem_usage=True
)

tokenizer = AutoTokenizer.from_pretrained(model_name)
```

(c) **Tích hợp tokenizer và model thành một pipeline để tiện sử dụng:**

```
model_pipeline = pipeline(
    "text-generation",
    model=model,
    tokenizer=tokenizer,
```

```
    max_new_tokens=512,
    pad_token_id=tokenizer.eos_token_id,
    device_map="auto"
)

llm = HuggingFacePipeline(
    pipeline=model_pipeline,
)
```

4. **Chạy chương trình:** Với vector database, retriever và mô hình Vicuna đã hoàn thiện. Ta sẽ kết hợp chúng lại để hoàn thành chương trình RAG đầu tiên của mình. Các bạn có thể test thử bằng cách đặt các câu hỏi có liên quan đến file tài liệu, câu trả lời của mô hình sẽ nằm ở phần **"Answer:"** trong output.

```
prompt = hub.pull("rlm/rag-prompt")

def format_docs(docs):
    return "\n\n".join(doc.page_content for doc in docs)

rag_chain = (
    {"context": retriever | format_docs, "question": RunnablePassthrough
    ()}
    | prompt
    | llm
    | StrOutputParser()
)

USER_QUESTION = "YOLOv10 là gì?"
output = rag_chain.invoke(USER_QUESTION)
answer = output.split('Answer:')[1].strip()
print(answer)
```

```
Human: You are an assistant for question-answering tasks. Use the following pieces of retrieved context
Question: YOLO là gì?
Context: Quan sát kết quả trên, ta có thể thấy trên cùng một phiên bản, YOLOv10 có mức độ tối ưu tốt
hơn về mặt tham số mô hình cũng như độ trễ trong inference trong khi vẫn giữ được độ chính
xác ngang hoặc hơn so với các phiên bản trước.
18

khác.
-Ưu điểm : Cân bằng tốt giữa tốc độ và độ chính xác, dễ dàng sử dụng và triển khai.
-Nhược điểm : Yêu cầu phần cứng mạnh để đạt hiệu năng tối ưu.
5

AI VIETNAM (AIO2024) aivietnam.edu.vn
Hình 8: PGI và các kiến trúc tương tự. Ảnh: [9].
-Điểm mới : YOLOv9 sử dụng PGI và GELAN để cải thiện độ chính xác và hiệu suất của
mô hình.
-Ưu điểm :
+ Kiến trúc tiên tiến: Sử dụng PGI và GELAN giúp mô hình duy trì thông tin quan
trọng và tối ưu hóa quá trình huấn luyện, làm cho YOLOv9 trở nên mạnh mẽ và linh
hoạt hơn trong nhiều ứng dụng khác nhau.
+ Tốc độ nhanh hơn: YOLOv9 có thể xử lý hình ảnh nhanh hơn so với YOLOv8 nhờ
vào các cải tiến trong kiến trúc mạng.
-Nhược điểm :
+ Mặc dù nhanh hơn YOLOv8, YOLOv9 vẫn yêu cầu nhiều tài nguyên tính toán, đặc
biệt là khi xử lý hình ảnh độ phân giải cao.
...
phiên bản YOLO trước đó ở các khía cạnh khác nhau, tăng cường khả năng phát hiện đối tượng
theo thời gian thực (real-time object detection).
1
Answer: YOLO là một hệ thống mô hình máy học được sử dụng cho việc phát hiện đối tượng trong hình ảnh.
```

Hình 7: Minh họa kết quả đầu ra của chương trình.

Như vậy, chúng ta đã hoàn thành một chương trình Python về RAG, có khả năng hỏi đáp các nội dung trong một file pdf.

II.II. Xây dựng giao diện chat

Sau khi có chương trình RAG có thể trả về output đúng như dự định, ta có thể tích hợp vào với một giao diện chat để có được một ứng dụng chat hoàn chỉnh. Để xây dựng phần giao diện trong project này, chúng ta sẽ sử dụng thư viện Chainlit. Lưu ý rằng, phần code Chainlit có sử dụng những đoạn code Python phức tạp, các bạn mới chỉ cần xem và chạy dưới dạng blackbox.

Hình 8: Chainlit, một thư viện hỗ trợ giao diện cho các ứng dụng về chatbot. Ảnh: link.

Các bước thực hiện như sau:

1. **Tải các gói thư viện:**

```
!pip install -q transformers==4.41.2
!pip install -q bitsandbytes==0.43.1
!pip install -q accelerate==0.31.0
!pip install -q langchain==0.2.5
!pip install -q langchainhub==0.1.20
!pip install -q langchain-chroma==0.1.1
!pip install -q langchain-community==0.2.5
!pip install -q langchain-openai==0.1.9
!pip install -q langchain_huggingface==0.0.3
!pip install -q chainlit==1.1.304
!pip install -q python-dotenv==1.0.1
!pip install -q pypdf==4.2.0
!npm install -g localtunnel
!pip install -q numpy==1.24.4
```

2. **Import các gói thư viện cần thiết:**

```
import chainlit as cl
import torch

from chainlit.types import AskFileResponse

from transformers import BitsAndBytesConfig
from transformers import AutoTokenizer, AutoModelForCausalLM, pipeline
from langchain_huggingface.llms import HuggingFacePipeline

from langchain.memory import ConversationBufferMemory
from langchain_community.chat_message_histories import ChatMessageHistory
```

```
from langchain.chains import ConversationalRetrievalChain

from langchain_huggingface import HuggingFaceEmbeddings
from langchain_chroma import Chroma
from langchain_community.document_loaders import PyPDFLoader, TextLoader
from langchain_text_splitters import RecursiveCharacterTextSplitter
from langchain_core.runnables import RunnablePassthrough
from langchain_core.output_parsers import StrOutputParser
from langchain import hub
```

3. **Cài đặt lại các hàm và instance ở file trước:** Chúng ta khai báo lại một số hàm và instance ở phần trước. Các bạn có thể quay lại mục trước để xem phần giải thích:

```
text_splitter = RecursiveCharacterTextSplitter(chunk_size=1000,
                                               chunk_overlap=100)

embedding = HuggingFaceEmbeddings()
```

4. **Xây dựng hàm xử lý file input đầu vào:** Để thuận tiện trong việc cài đặt, ta gom việc đọc và tách văn bản vào chung một hàm như sau:

```
def process_file(file: AskFileResponse):
    if file.type == "text/plain":
        Loader = TextLoader
    elif file.type == "application/pdf":
        Loader = PyPDFLoader

    loader = Loader(file.path)
    documents = loader.load()
    docs = text_splitter.split_documents(documents)
    for i, doc in enumerate(docs):
        doc.metadata["source"] = f"source_{i}"
    return docs
```

5. **Xây dựng hàm khởi tạo Chroma database:** Tương tự phía trên, ta xây dựng hàm khởi tạo vector database cho phần cài đặt này:

```
def get_vector_db(file: AskFileResponse):
    docs = process_file(file)
    cl.user_session.set("docs", docs)
    vector_db = Chroma.from_documents(documents=docs,
                                      embedding=embedding)
    return vector_db
```

Tại line 2, gọi hàm `process_file()` để xử lý file input và trả về các tài liệu nhỏ (docs). Sau đó, khởi tạo Chroma vector database bằng cách gọi `Chroma.from_documents()` và truyền vào docs cũng như embedding đã khởi tạo trước đó.

6. **Khởi tạo mô hình ngôn ngữ lớn:**

```
def get_huggingface_llm(model_name: str = "lmsys/vicuna-7b-v1.5",
                        max_new_token: int = 512):
    nf4_config = BitsAndBytesConfig(
        load_in_4bit=True,
        bnb_4bit_quant_type="nf4",
```

```
        bnb_4bit_use_double_quant=True,
        bnb_4bit_compute_dtype=torch.bfloat16
    )
    model = AutoModelForCausalLM.from_pretrained(
        model_name,
        quantization_config=nf4_config,
        low_cpu_mem_usage=True
    )
    tokenizer = AutoTokenizer.from_pretrained(model_name)

    model_pipeline = pipeline(
        "text-generation",
        model=model,
        tokenizer=tokenizer,
        max_new_tokens=max_new_token,
        pad_token_id=tokenizer.eos_token_id,
        device_map="auto"
    )

    llm = HuggingFacePipeline(
        pipeline=model_pipeline,
    )
    return llm

LLM = get_huggingface_llm()
```

7. **Khởi tạo welcome message:**

```
welcome_message = """Welcome to the PDF QA! To get started:
1. Upload a PDF or text file
2. Ask a question about the file
"""
```

8. **Khởi tạo hàm on_chat_start:**

```
@cl.on_chat_start
async def on_chat_start():
    files = None
    while files is None:
        files = await cl.AskFileMessage(
            content=welcome_message,
            accept=["text/plain", "application/pdf"],
            max_size_mb=20,
            timeout=180,
        ).send()
    file = files[0]

    msg = cl.Message(content=f"Processing `{file.name}`...",
                     disable_feedback=True)
    await msg.send()

    vector_db = await cl.make_async(get_vector_db)(file)

    message_history = ChatMessageHistory()
    memory = ConversationBufferMemory(
```

```
        memory_key="chat_history",
        output_key="answer",
        chat_memory=message_history,
        return_messages=True,
    )
    retriever = vector_db.as_retriever(search_type="mmr",
                                       search_kwargs={'k': 3})

    chain = ConversationalRetrievalChain.from_llm(
        llm=LLM,
        chain_type="stuff",
        retriever=retriever,
        memory=memory,
        return_source_documents=True
    )

    msg.content = f"`{file.name}` processed. You can now ask questions!"
    await msg.update()

    cl.user_session.set("chain", chain)
```

9. **Khởi tạo hàm on_message:**

```
@cl.on_message
async def on_message(message: cl.Message):
    chain = cl.user_session.get("chain")
    cb = cl.AsyncLangchainCallbackHandler()
    res = await chain.ainvoke(message.content, callbacks=[cb])
    answer = res["answer"]
    source_documents = res["source_documents"]
    text_elements = []

    if source_documents:
        for source_idx, source_doc in enumerate(source_documents):
            source_name = f"source_{source_idx}"
            text_elements.append(
                cl.Text(content=source_doc.page_content,
                        name=source_name)
            )
        source_names = [text_el.name for text_el in text_elements]

        if source_names:
            answer += f"\nSources: {', '.join(source_names)}"
        else:
            answer += "\nNo sources found"

    await cl.Message(content=answer, elements=text_elements).send()
```

10. **Chạy chainlit app:**

```
!chainlit run app.py --host 0.0.0.0 --port 8000 &>/content/logs.txt &
```

11. **Expose localhost thành public host bằng localtunnel:**

```
import urllib
```

```
print("Password/Enpoint IP for localtunnel is:",urllib.request.urlopen('
    https://ipv4.icanhazip.com').read().decode('utf8').strip("\n"))
```

```
!lt --port 8000 --subdomain aivn-simple-rag
```

Khi chạy xong các bước trên, các bạn truy cập vào đường dẫn tạm localtunnel, nhập password được cung cấp để truy cập vào giao diện web. Lưu ý rằng, phương án sử dụng localtunnel là một phương án truy cập vào localhost trên Colab đơn giản nhưng có thể có lúc không hoạt động được. Nếu có máy tính có GPU, các bạn có thể đưa code này chạy ở máy để tiện sử dụng và đảm bảo đầu ra hơn.

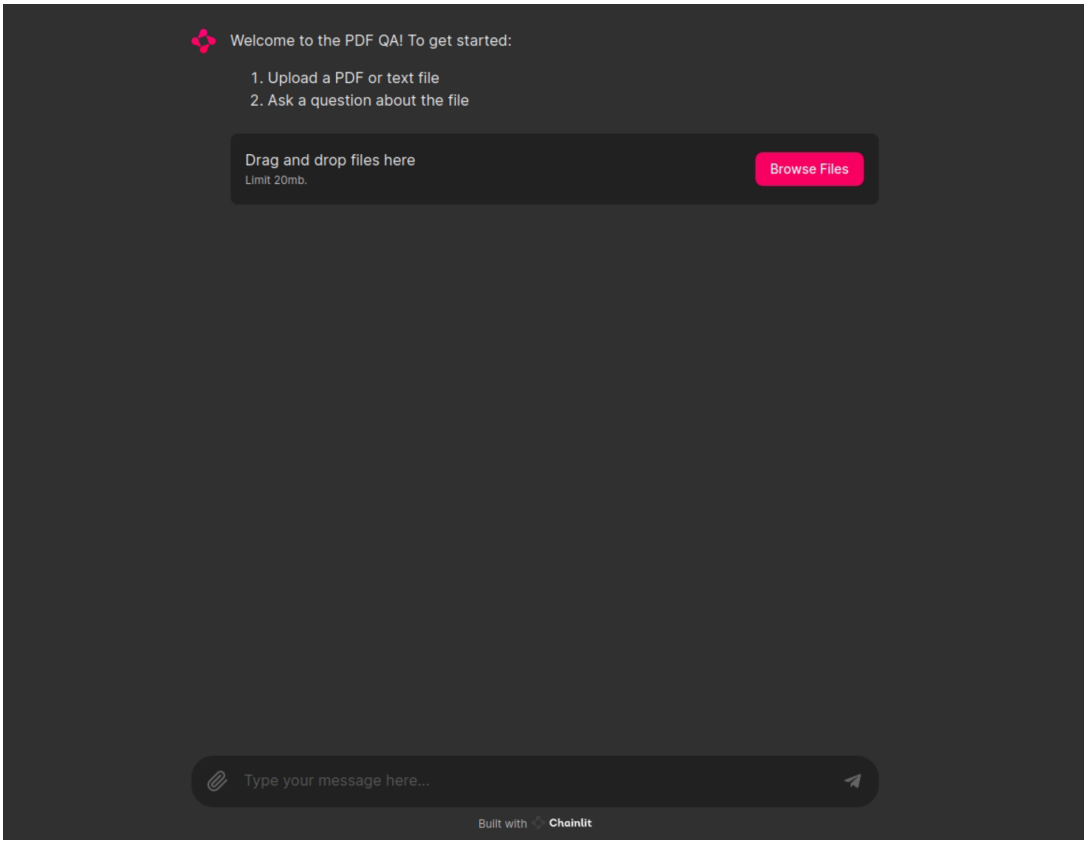

Hình 9: Giao diện chat trong chương trình.

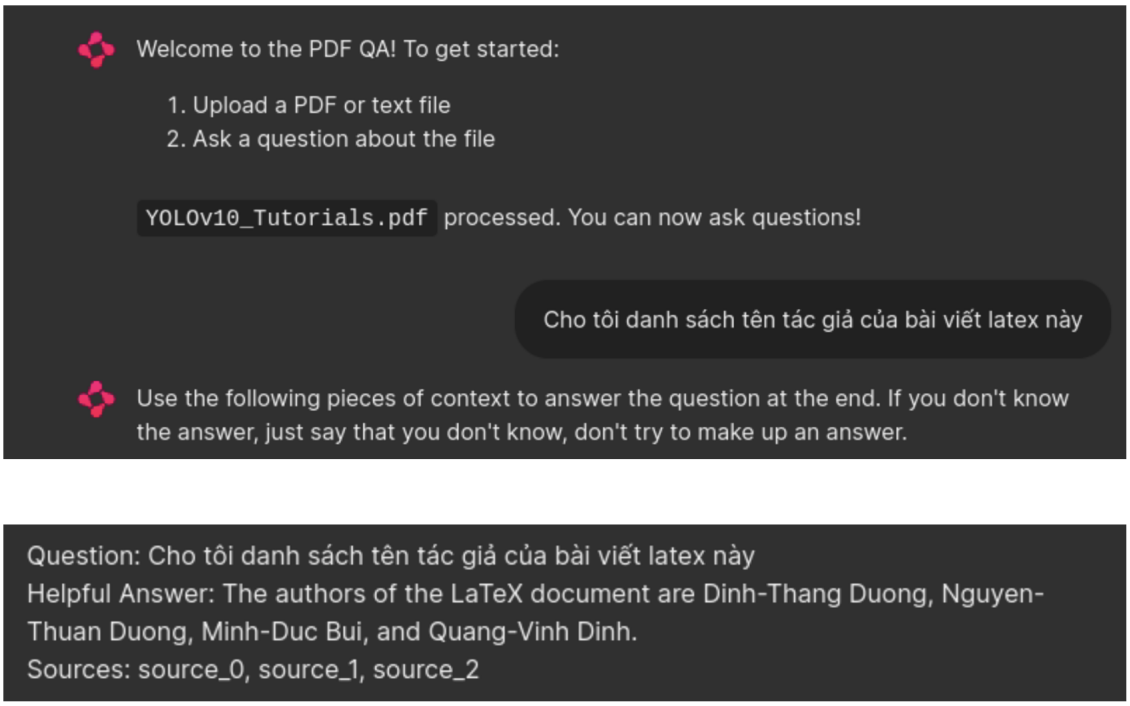

Hình 10: Thử nghiệm một đoạn chat trên giao diện chúng ta vừa hoàn thành.

III. Câu hỏi trắc nghiệm

1. RAG là viết tắt của cụm từ nào sau đây trong ngữ cảnh mô hình ngôn ngữ lớn (LLM)?
   (*a*) Randomized Augmentation Generator.
   (*b*) Retrieval Augmented Generation.
   (*c*) Recurrent Adaptive Generator.
   (*d*) Recursive Algorithmic Generator.

2. Kỹ thuật RAG cải thiện mô hình ngôn ngữ lớn bằng cách nào ?
   (*a*) Truy vấn thêm các thông tin bên ngoài.
   (*b*) Dùng google search.
   (*c*) Cải thiện việc sai chính tả.
   (*d*) Bỏ dấu câu.

3. Input và Ouput trong hệ thống RAG cho bài toán PDF Question-Answering là gì?
   (*a*) Input là video, Ouput là text.
   (*b*) Input là text, Ouput là text.
   (*c*) Input là image và text, Ouput là text.
   (*d*) Input là pdf và text, Ouput là text.

4. Trước khi sinh ra câu trả lời, RAG sẽ làm gì ?
   (*a*) Tạo một chuỗi text ngẫu nhiên.
   (*b*) Dịch câu hỏi đầu vào sang một ngôn ngữ khác.
   (*c*) Truy vấn các thông tin liên quan đến câu hỏi.
   (*d*) Kiểm tra chính tả của câu hỏi đầu vào.

5. Trong RAG, vì sao lại cần chuyển đổi các đoạn văn bản thành vector?
   (*a*) Để giảm chi phí tính toán trong quá trình ánh xạ văn bản vào không gian vector.
   (*b*) Để tăng tính ngẫu nhiên và sáng tạo trong quá trình sinh câu trả lời.
   (*c*) Để tăng tốc độ xử lý và giảm thời gian huấn luyện mô hình.
   (*d*) Để mô hình có thể hiểu và xử lý thông tin dưới dạng số học, dễ dàng tính toán và so sánh.

6. Chức năng của đoạn code dưới đây là gì ?

```
from langchain_text_splitters import RecursiveCharacterTextSplitter

text_splitter = RecursiveCharacterTextSplitter(chunk_size=1000,
                                               chunk_overlap=100)
```

   (*a*) Khởi tạo bộ chia text.

(*b*) Khởi tạo bộ chia vector.

(*c*) Import text từ langchain.

(*d*) Truy vấn text.

7. Tại sao cần phải có vector database trong hệ thống RAG?

(*a*) Giúp hệ thống chạy nhanh hơn.

(*b*) Làm cho hệ thống bảo mật cao hơn.

(*c*) Thuận tiện cho việc truy vấn thông tin có liên quan.

(*d*) Lưu trữ hiệu quả.

8. Cho đoạn code sau, chức năng của **embedding** là gì ?

```
from langchain_huggingface import HuggingFaceEmbeddings

embedding = HuggingFaceEmbeddings()
```

(*a*) Là mô hình LLM.

(*b*) Dùng để chuyển văn bản thành vector.

(*c*) Dùng để truy vấn thông tin văn bản.

(*d*) Là một vector database.

9. Chainlit là gì ?

(*a*) Là một thư viện giúp xây dựng các ứng dụng hội thoại với AI.

(*b*) Là một phần mềm chatbot.

(*c*) Là giao diện tích hợp chatGPT.

(*d*) Là một thư viện để huấn luyên AI.

10. Câu lệnh nào sau đây dùng để khởi chạy chainlit ?

(*a*) run chainlit

(*b*) chainlit run –app.py

(*c*) chainlit run

(*d*) chainlit run app.py